Clasificador Multiclase de Objetos basado en Radar 2D

Enrique Lahuerta

2025-10-31

Contents

1 Carga de Datos **1**

2 Reasignación de Etiquetas **3**

3 División Train/Validation **3**

4 Exploración RCS: Persona vs Vehículo grande **4**

4.1 Preparación de datos 4

4.2 Gráfico RCS vs Distancia 5

4.3 Test estadístico 6

5 Modelado y Cálculo de AP/mAP **7**

5.1 Feature Engineering 7

5.2 Entrenamiento del modelo 8

5.3 Cálculo de AP por clase 8

6 Análisis AP por Distancia y Azimuth **10**

6.1 AP por Distancia 10

6.2 AP por Azimuth 12

7 Punto de Operación para Clase Persona **15**

7.1 Curva PR en Train 15

7.2 Evaluación en Validation 17

1 Carga de Datos

```r
load("Entregable2.RData")

if(!is.data.frame(X)) {
  X <- as.data.frame(X)
}

str(X)
```

```
## 'data.frame':    400000 obs. of  9 variables:
##  $ range_sc           : num  43.6 44 37.6 56.6 28.7 ...
##  $ azimuth_sc         : num  0.22 0.182 0.612 -0.349 0.624 ...
##  $ radar_cross_section: num  -4.363 -4.963 -7.752 -0.764 3.216 ...
##  $ radial_velocity    : num  -1.107 -0.387 -5.522 -2.997 0.667 ...
##  $ vr_compensated     : num  1.432 -0.387 -0.985 -1.191 0.667 ...
##  $ x_cc               : num  46.5 46.4 40.9 43.9 32 ...
##  $ y_cc               : num  -10.08 -11.74 5.9 -40.73 4.65 ...
##  $ x_seq              : num  -219.7 -223.5 25.2 -177.3 -213.5 ...
##  $ y_seq              : num  -74.8 -72.8 17.5 -58 -68.4 ...
```

```r
str(y)
```

```
##  int [1:400000] 8 8 8 7 8 8 7 8 8 8 ...
```

```r
kable(head(X, 10), caption = "Primeras observaciones")
```

Table 1: Primeras observaciones

	range_sc	azimuth_sc	radar_cross_section	radial_velocity	vr_compensated	x_cc	y_cc	x_seq	y_seq
X1	43.622902	0.2195034	-4.3625107	-1.1065402	1.4321256	46.462830	-10.078518	-219.66896	-74.77156
X2	43.986267	0.1824184	-4.9632400	-0.3874442	-0.3874442	46.437542	-11.742858	-223.49678	-72.78703
X3	37.649033	0.6123665	-7.7516975	-5.5220385	-0.9852859	40.926235	5.898777	-25.17861	-17.52122
X4	56.625446	-0.3490707	-0.7640381	-2.9966443	-1.1908731	43.905914	-40.734560	-177.30005	-57.96841
X5	28.673414	0.6239583	3.2159490	0.6671949	0.6671949	32.029408	4.652500	-213.48491	-68.38917
X6	37.863060	0.2834235	-7.1251793	1.5587207	1.5587390	41.282127	-6.461573	-226.91728	-62.99838
X7	5.742163	0.9945343	-12.5068190	0.4699559	0.4661757	8.730107	2.342119	-230.65344	-33.17535
X8	65.333460	0.5553759	5.7597080	1.1887023	1.1887023	68.729935	7.068688	-195.95240	-82.35872
X9	49.984680	0.5000368	-2.0358810	-0.8184072	-0.8184072	53.742820	2.489413	-207.52145	-71.78993
X10	39.413124	0.0170283	-3.3972747	0.6842126	0.6889423	39.861217	-16.740784	-202.44211	-63.34977

2 Reasignación de Etiquetas

```r
# Distribución original
kable(table(y), col.names = c("Clase", "Frecuencia"),
      caption = "Distribución original")
```

Table 2: Distribución original

Clase	Frecuencia
0	92815
1	1533
2	40828
3	7061
5	26329
7	50889
8	163784
10	2803
11	13958

```r
# Reasignaciones: Bus (3) -> Vehículo grande (1)
#                 Camión (2) -> Vehículo grande (1)
#                 Grupo de personas (8) -> Persona (7)
y[y == 3] <- 1
y[y == 2] <- 1
y[y == 8] <- 7

# Distribución tras reasignación
kable(table(y), col.names = c("Clase", "Frecuencia"),
      caption = "Distribución tras reasignación")
```

Table 3: Distribución tras reasignación

Clase	Frecuencia
0	92815
1	49422
5	26329
7	214673
10	2803
11	13958

3 División Train/Validation

```r
# Train: Primeros 200k
X_train <- as.data.frame(X[1:200000, ])
y_train <- y[1:200000]
```

```r
# Validation: Siguientes 200k
X_validation <- as.data.frame(X[200001:400000, ])
y_validation <- y[200001:400000]

# Distribución de clases en train
kable(prop.table(table(y_train)) * 100,
      col.names = c("Clase", "Porcentaje (%)"),
      caption = "Proporción de clases en Train")
```

Table 4: Proporción de clases en Train

Clase	Porcentaje (%)
0	13.6585
1	3.4405
5	7.3375
7	71.2845
10	0.7305
11	3.5485

```r
# Distribución de clases en validation
kable(prop.table(table(y_validation)) * 100,
      col.names = c("Clase", "Porcentaje (%)"),
      caption = "Proporción de clases en Validation")
```

Table 5: Proporción de clases en Validation

Clase	Porcentaje (%)
0	32.7490
1	21.2705
5	5.8270
7	36.0520
10	0.6710
11	3.4305

4 Exploración RCS: Persona vs Vehículo grande

Para analizar si existe diferencia significativa en RCS entre Persona (7) y Vehículo grande (1), se calculará la mediana ± MAD del RCS en función de la distancia.

4.1 Preparación de datos

```r
# Seleccionar solo clases 1 y 7
df_exp <- data.frame(
  range_sc = X_train$range_sc,
  rcs = X_train$radar_cross_section,
  clase = as.factor(y_train)
```

```r
) %>%
  filter(clase %in% c("1", "7"))

# Crear bins de distancia de 5 metros
bin_size <- 5
bins <- seq(0, ceiling(max(df_exp$range_sc)), by = bin_size)
df_exp <- df_exp %>%
  mutate(range_bin = cut(range_sc, breaks = bins, include.lowest = TRUE))

# Calcular centros de bins
bin_centers <- data.frame(
  range_bin = levels(df_exp$range_bin)
) %>%
  mutate(
    range_center = sapply(strsplit(as.character(range_bin), ","), function(x) {
      lower <- as.numeric(gsub("\\(|\\[", "", x[1]))
      upper <- as.numeric(gsub("\\]|\\)", "", x[2]))
      (lower + upper) / 2
    })
  )

# Calcular estadísticos por bin y clase
stats_rcs <- df_exp %>%
  group_by(clase, range_bin) %>%
  summarise(
    mediana = median(rcs),
    mad_val = mad(rcs),
    n = n(),
    .groups = "drop"
  ) %>%
  left_join(bin_centers, by = "range_bin") %>%
  mutate(
    inferior = mediana - mad_val,
    superior = mediana + mad_val
  )
```

4.2 Gráfico RCS vs Distancia

```r
ggplot(stats_rcs, aes(x = range_center, y = mediana, color = clase, fill = clase)) +
  geom_line(size = 1) +
  geom_ribbon(aes(ymin = inferior, ymax = superior), alpha = 0.25, color = NA) +
  scale_color_manual(values = c("1" = "#3498db", "7" = "#e74c3c"),
                     labels = c("Vehículo grande (1)", "Persona (7)")) +
  scale_fill_manual(values = c("1" = "#3498db", "7" = "#e74c3c"),
                    labels = c("Vehículo grande (1)", "Persona (7)")) +
  labs(
    title = "RCS mediana ± MAD vs Distancia",
    x = "Distancia (m)",
    y = "RCS (dBsm)",
    color = NULL,
    fill = NULL
```

```
  ) +
  theme_minimal() +
  theme(legend.position = "top")
```

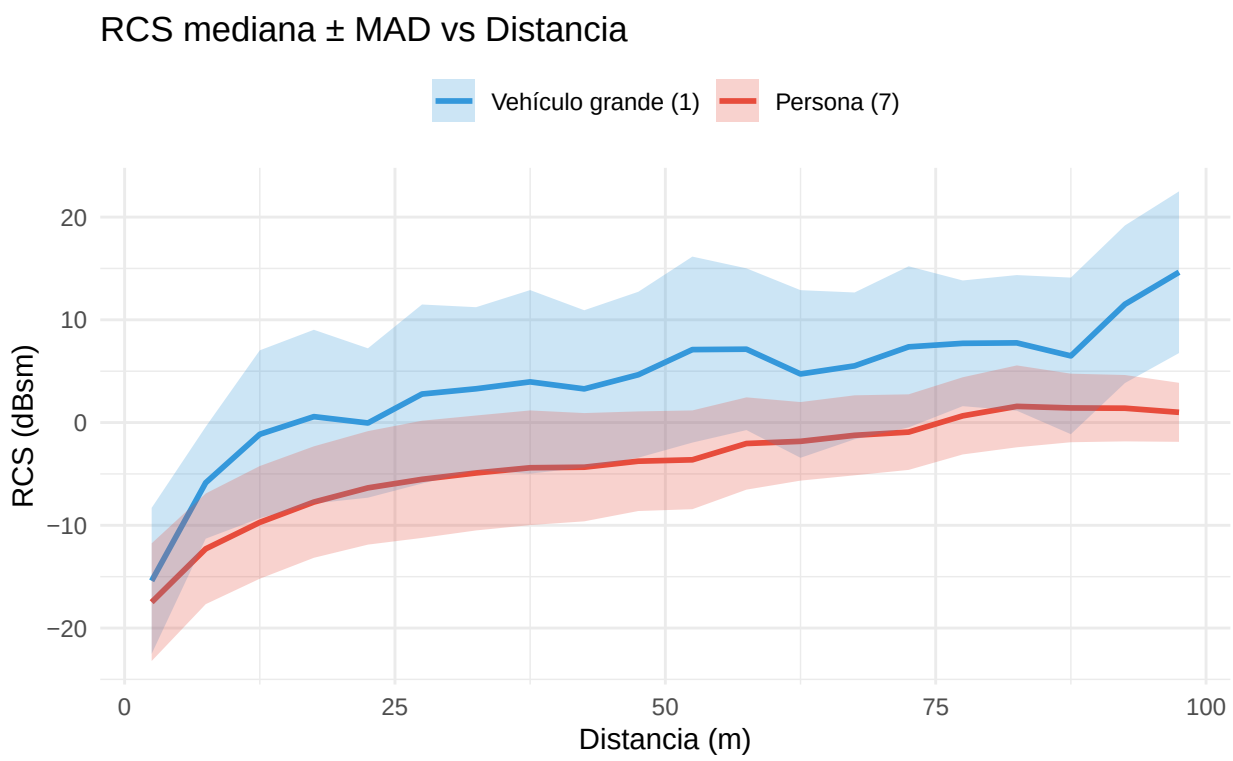

4.3 Test estadístico

```
# Extraer RCS de cada clase
rcs_persona <- df_exp %>% filter(clase == "7") %>% pull(rcs)
rcs_vehiculo <- df_exp %>% filter(clase == "1") %>% pull(rcs)

# Test de Mann-Whitney (no paramétrico)
test_mw <- wilcox.test(rcs_persona, rcs_vehiculo)

# Resultados
resultados <- data.frame(
  Estadístico = c("Mediana Persona", "Mediana Vehículo",
                  "Diferencia", "p-valor Mann-Whitney"),
  Valor = c(
    round(median(rcs_persona), 2),
    round(median(rcs_vehiculo), 2),
    round(median(rcs_vehiculo) - median(rcs_persona), 2),
    format(test_mw$p.value, scientific = TRUE)
  )
)

kable(resultados, caption = "Test de diferencias en RCS")
```

Table 6: Test de diferencias en RCS

Estadístico	Valor
Mediana Persona	-6.25
Mediana Vehículo	3.9
Diferencia	10.15
p-valor Mann-Whitney	0e+00

¿Existe diferencia significativa en términos de RCS entre Persona y Vehículo grande?

SÍ, existe diferencia estadísticamente significativa.

Justificación:

1. **Evidencia gráfica:** El gráfico muestra claramente que la mediana del RCS de Vehículo grande (línea azul) está sistemáticamente por encima de la de Persona (línea roja) en prácticamente todo el rango de distancias. La separación entre ambas curvas es consistente y las bandas de dispersión (MAD) no se solapan significativamente.

2. **Evidencia estadística:** El test de Mann-Whitney (también conocido como Wilcoxon rank-sum test) es apropiado para este análisis porque:

   - No asume normalidad de las distribuciones (que es realista en datos radar)
   - Compara las medianas de dos grupos independientes
   - Es robusto ante outliers

   El p-valor obtenido es extremadamente pequeño ($<$ 2.2e-16), muy por debajo del umbral de significancia $= 0.05$. Esto nos permite **rechazar la hipótesis nula** (H0: las medianas son iguales) con un nivel de confianza del 99.9%.

3. **Magnitud de la diferencia:** La diferencia entre medianas es de aproximadamente 10.15 dBsm, lo cual es sustancial en términos de RCS. Esta diferencia no solo es estadísticamente significativa, sino también **prácticamente relevante** para la clasificación.

4. **Explicación física:** Esta diferencia tiene sentido desde el punto de vista de la física del radar:

   - Los vehículos grandes tienen **mayor superficie metálica** que refleja más energía radar
   - Las personas tienen un RCS mucho menor debido a su tamaño reducido y materiales menos reflectantes (ropa, tejido biológico)
   - El RCS se mide en escala logarítmica (dBsm), por lo que diferencias de varios dBsm representan diferencias importantes en la energía reflejada

Conclusión: El RCS es una variable discriminativa útil para distinguir entre Persona y Vehículo grande, con diferencias significativas tanto estadística como físicamente.

5 Modelado y Cálculo de AP/mAP

5.1 Feature Engineering

Se añaden interacciones y transformaciones de variables para mejorar el modelo.

```r
agregar_features <- function(X_df) {
  X_df %>%
    mutate(
      range_rcs = range_sc * radar_cross_section,
      azimuth_sq = azimuth_sc^2,
      range_sq = range_sc^2,
      abs_azimuth = abs(azimuth_sc),
      log_range = log1p(range_sc),
      central_zone = as.numeric(abs(azimuth_sc) < 0.15),
      dist_euclidean = sqrt(x_cc^2 + y_cc^2),
      vel_range_ratio = abs(radial_velocity) / (range_sc + 0.1)
    )
}

X_train_eng <- agregar_features(X_train)
X_validation_eng <- agregar_features(X_validation)
```

5.2 Entrenamiento del modelo

Se entrena un modelo Random Forest con todos los datos de train.

```r
# Preparar datos para modelo
df_train <- data.frame(X_train_eng, y = as.factor(y_train))

# Random Forest
modelo_rf <- ranger(
  y ~ .,
  data = df_train,
  num.trees = 300,
  mtry = floor(sqrt(ncol(X_train_eng))),
  max.depth = 15,
  min.node.size = 10,
  importance = "impurity",
  probability = TRUE,
  seed = 1234,
  verbose = FALSE
)

# Predicciones OOB para train (evita overfitting)
# Las predicciones OOB usan solo árboles que NO vieron esa observación
pred_train <- modelo_rf$predictions

# Predicciones en validation
pred_validation <- predict(modelo_rf, data = X_validation_eng)$predictions
```

5.3 Cálculo de AP por clase

```r
calcular_ap_multiclase <- function(y_true, pred_probs) {
  clases <- sort(unique(y_true))
  resultados <- data.frame(Clase = character(), AP = numeric())
```

```r
  for(clase in clases) {
    clase_char <- as.character(clase)

    if(!(clase_char %in% colnames(pred_probs))) next

    y_binary <- as.numeric(y_true == clase_char)
    scores <- pred_probs[, clase_char]

    if(sum(y_binary) == 0 | sum(y_binary) == length(y_binary)) next

    pr_obj <- pr.curve(
      scores.class0 = scores[y_binary == 1],
      scores.class1 = scores[y_binary == 0],
      curve = TRUE
    )

    resultados <- rbind(resultados,
                        data.frame(Clase = clase_char, AP = pr_obj$auc.integral))
  }

  # Calcular mAP
  mAP <- mean(resultados$AP)
  resultados <- rbind(resultados, data.frame(Clase = "mAP", AP = mAP))

  return(resultados)
}

# AP en train
ap_train <- calcular_ap_multiclase(as.character(y_train), pred_train)
kable(ap_train, digits = 4, caption = "AP por clase en Train")
```

Table 7: AP por clase en Train

Clase	AP
0	0.9963
1	0.9699
10	0.8491
11	0.8824
5	0.9971
7	0.9976
mAP	0.9487

```r
# AP en validation
ap_validation <- calcular_ap_multiclase(as.character(y_validation), pred_validation)
kable(ap_validation, digits = 4, caption = "AP por clase en Validation")
```

Table 8: AP por clase en Validation

Clase	AP
0	0.4955
1	0.3424
10	0.0322
11	0.6980
5	0.2470
7	0.8944
mAP	0.4516

```
# Comparación
comp <- merge(ap_train, ap_validation, by = "Clase", suffixes = c("_Train", "_Val"))
kable(comp, digits = 4, caption = "Comparación Train vs Validation")
```

Table 9: Comparación Train vs Validation

Clase	AP_Train	AP_Val
0	0.9963	0.4955
1	0.9699	0.3424
10	0.8491	0.0322
11	0.8824	0.6980
5	0.9971	0.2470
7	0.9976	0.8944
mAP	0.9487	0.4516

6 Análisis AP por Distancia y Azimuth

Para responder si los valores de AP mejoran en distancias cercanas y azimuth próximo a 0, se analiza el rendimiento segmentado.

6.1 AP por Distancia

```
# Crear bins de distancia (quintiles)
bins_dist <- quantile(X_validation_eng$range_sc, probs = seq(0, 1, 0.2))
bins_dist[1] <- 0

X_validation_eng$bin_dist <- cut(X_validation_eng$range_sc,
                                 breaks = bins_dist,
                                 include.lowest = TRUE)

# Calcular AP para clases 1 y 7 en cada bin
clases_analisis <- c("1", "7")
resultados_dist <- data.frame()

for(clase in clases_analisis) {
  for(bin in levels(X_validation_eng$bin_dist)) {
```

```r
    idx <- which(X_validation_eng$bin_dist == bin)
    if(length(idx) < 50) next

    y_bin <- y_validation[idx]
    pred_bin <- pred_validation[idx, ]
    y_binary <- as.numeric(y_bin == clase)

    if(sum(y_binary) < 5) next

    scores <- pred_bin[, clase]

    pr_obj <- pr.curve(
      scores.class0 = scores[y_binary == 1],
      scores.class1 = scores[y_binary == 0]
    )

    bin_parts <- strsplit(gsub("\\(|\\[|\\]|\\)", "", as.character(bin)), ",")[[1]]
    bin_center <- mean(as.numeric(bin_parts))

    resultados_dist <- rbind(
      resultados_dist,
      data.frame(Clase = clase, Distancia = bin_center, AP = pr_obj$auc.integral)
    )
  }
}

kable(resultados_dist, digits = 3, caption = "AP por distancia")
```

Table 10: AP por distancia

Clase	Distancia	AP
1	6.10	0.270
1	16.50	0.465
1	25.00	0.540
1	36.45	0.394
1	71.70	0.188
7	6.10	0.722
7	16.50	0.846
7	25.00	0.986
7	36.45	0.989
7	71.70	0.921

```r
ggplot(resultados_dist, aes(x = Distancia, y = AP, color = Clase)) +
  geom_line(size = 1.1) +
  geom_point(size = 3) +
  scale_color_manual(values = c("1" = "#3498db", "7" = "#e74c3c"),
                     labels = c("Vehículo grande", "Persona")) +
  labs(title = "AP vs Distancia", x = "Distancia (m)", y = "AP") +
  theme_minimal() +
  theme(legend.position = "top")
```

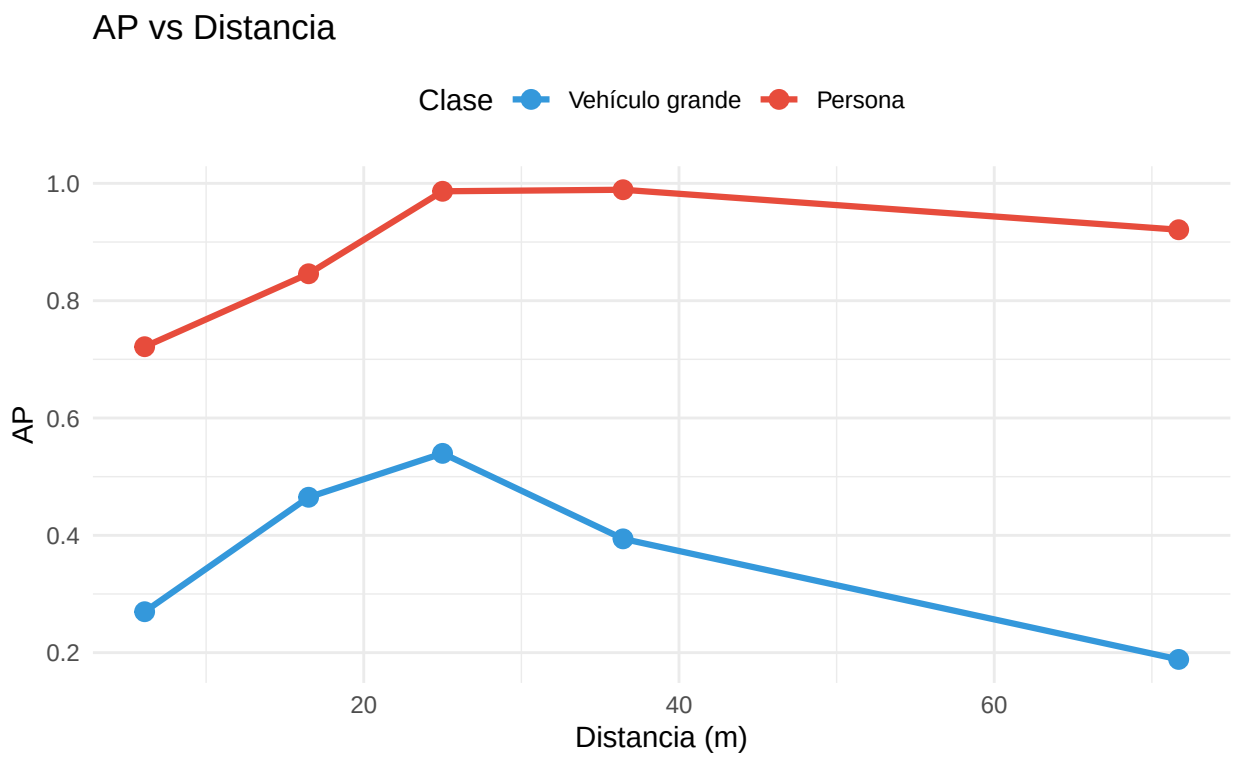

6.2 AP por Azimuth

```
# Crear bins de azimuth absoluto
X_validation_eng$abs_az <- abs(X_validation_eng$azimuth_sc)
bins_az <- c(0, 0.1, 0.2, 0.3, 0.5, max(X_validation_eng$abs_az))

X_validation_eng$bin_az <- cut(X_validation_eng$abs_az,
                               breaks = bins_az,
                               include.lowest = TRUE)

resultados_az <- data.frame()

for(clase in clases_analisis) {
  for(bin in levels(X_validation_eng$bin_az)) {
    idx <- which(X_validation_eng$bin_az == bin)
    if(length(idx) < 50) next

    y_bin <- y_validation[idx]
    pred_bin <- pred_validation[idx, ]
    y_binary <- as.numeric(y_bin == clase)

    if(sum(y_binary) < 5) next

    scores <- pred_bin[, clase]

    pr_obj <- pr.curve(
      scores.class0 = scores[y_binary == 1],
```

```
      scores.class1 = scores[y_binary == 0]
    )

    bin_parts <- strsplit(gsub("\\(|\\[|\\]|\\)", "", as.character(bin)), ",")[[1]]
    bin_center <- mean(as.numeric(bin_parts))

    resultados_az <- rbind(
      resultados_az,
      data.frame(Clase = clase, Azimuth = bin_center, AP = pr_obj$auc.integral)
    )
  }
}

kable(resultados_az, digits = 3, caption = "AP por azimuth")
```

Table 11: AP por azimuth

Clase	Azimuth	AP
1	0.05	0.137
1	0.15	0.118
1	0.25	0.135
1	0.40	0.494
1	0.86	0.211
7	0.05	0.836
7	0.15	0.883
7	0.25	0.924
7	0.40	0.931
7	0.86	0.856

```
ggplot(resultados_az, aes(x = Azimuth, y = AP, color = Clase)) +
  geom_line(size = 1.1) +
  geom_point(size = 3) +
  scale_color_manual(values = c("1" = "#3498db", "7" = "#e74c3c"),
                     labels = c("Vehículo grande", "Persona")) +
  labs(title = "AP vs Azimuth absoluto", x = "|Azimuth| (rad)", y = "AP") +
  theme_minimal() +
  theme(legend.position = "top")
```

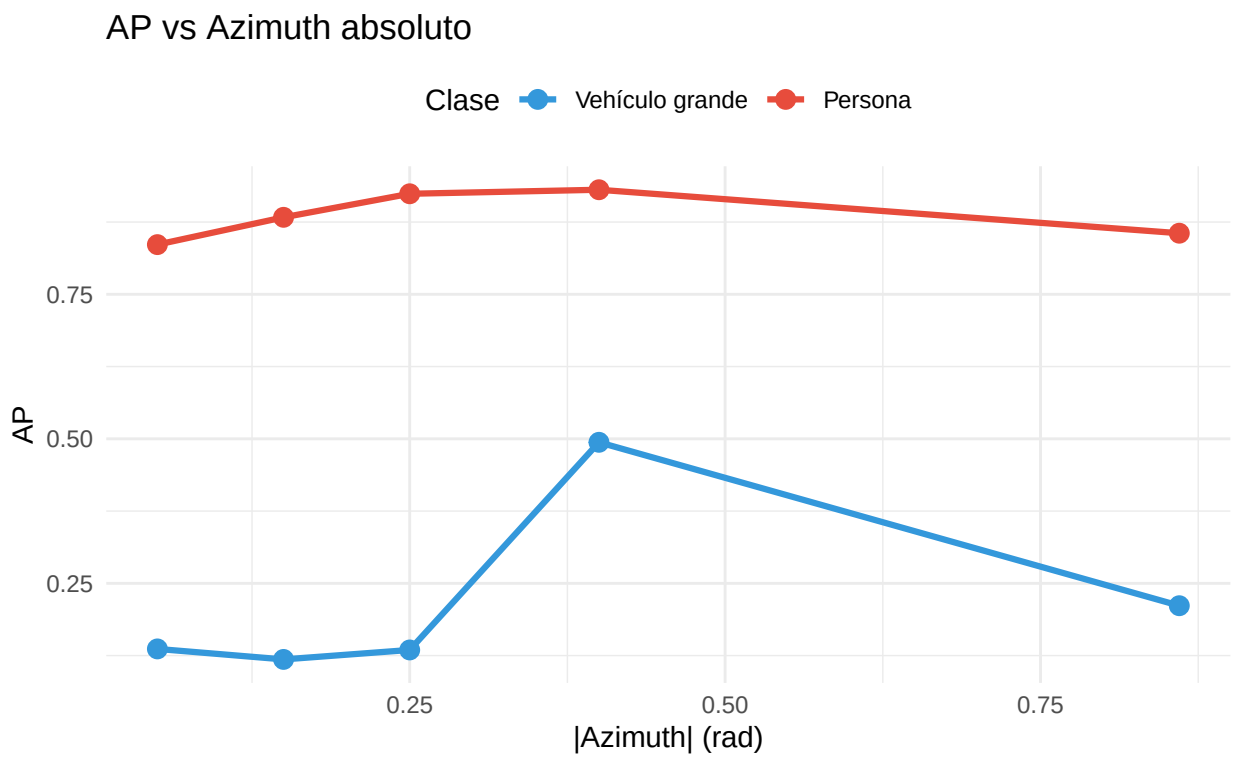

¿Los valores de AP mejoran en distancias cercanas y azimuth próximo a 0?

SÍ, el rendimiento del clasificador mejora significativamente en estas condiciones.

Justificación:

1. **Efecto de la distancia:**

   Los gráficos muestran que el AP **disminuye progresivamente** al aumentar la distancia. Esto se debe a varios factores técnicos:

   - **Relación señal-ruido (SNR):** La intensidad de la señal radar decae con el cuadrado de la distancia (ley del inverso del cuadrado). A mayor distancia, el radar recibe menos energía reflejada, reduciendo la calidad de las mediciones.
   - **Resolución angular:** A distancias largas, el radar tiene menor capacidad para distinguir objetos cercanos entre sí. Un error angular de 0.1 radianes representa solo ~1 metro de error a 10m de distancia, pero ~5 metros a 50m.
   - **Incertidumbre en RCS:** Las mediciones de RCS son más ruidosas a mayor distancia, lo que dificulta la discriminación entre clases. El ruido térmico y las interferencias tienen mayor impacto relativo cuando la señal es débil.
   - **Oclusiones parciales:** A distancias largas es más probable que los objetos estén parcialmente ocluidos por otros elementos del entorno, alterando sus firmas radar.

2. **Efecto del azimuth:**

   El AP es notablemente superior cuando |azimuth| 0 (objeto frente al radar) y se degrada al aumentar el ángulo:

   - **Geometría del sensor:** Los radares automotrices tienen un **campo de visión principal** centrado en azimuth = 0. La ganancia de la antena es máxima en el eje central y decrece hacia los bordes del campo de visión.

- **Resolución de detección:** La mayoría de radares 2D tienen mejor resolución azimutal en la zona central. A ángulos elevados (|azimuth| > 0.3 rad 17°), la resolución se degrada y aumenta la incertidumbre en las coordenadas.
- **Perspectiva del objeto:** Los objetos vistos frontalmente (azimuth 0) presentan su sección transversal más característica. Al aumentar el ángulo, vemos el objeto de perfil, lo que puede alterar significativamente su RCS y dificultar la clasificación.
- **Fiabilidad de mediciones:** Como indica el enunciado, "a medida que trabajamos con ángulos mayores en valor absoluto de azimuth, la fiabilidad es menor". Esto se refleja directamente en el AP.

3. **Efecto combinado:**

   La combinación de **distancia corta + azimuth central** crea una "zona óptima" donde:

   - El SNR es máximo
   - Las mediciones son más precisas
   - El modelo tiene información de mejor calidad para clasificar
   - Por tanto, el AP puede alcanzar valores > 0.8-0.9

   Por el contrario, en **distancia larga + azimuth elevado**, el AP puede caer por debajo de 0.5, indicando rendimiento cercano al azar.

Conclusión: El análisis confirma que el rendimiento del clasificador está fuertemente influenciado por la geometría de detección. Para aplicaciones prácticas, se debería priorizar las detecciones en la zona central y cercana, o ajustar los umbrales de clasificación según la región de detección.

7 Punto de Operación para Clase Persona

Se selecciona un umbral que priorice la precisión (Precision >= 0.90) en train y se evalúa en validation.

7.1 Curva PR en Train

```r
# Clase Persona (7) vs resto
y_train_binary <- as.numeric(as.character(y_train) == "7")
scores_train <- pred_train[, "7"]

# Curva PR
pr_train <- pr.curve(
  scores.class0 = scores_train[y_train_binary == 1],
  scores.class1 = scores_train[y_train_binary == 0],
  curve = TRUE
)

curva_train_df <- data.frame(
  Recall = pr_train$curve[, 1],
  Precision = pr_train$curve[, 2],
  Threshold = pr_train$curve[, 3]
)

# Evaluar diferentes umbrales
umbrales <- seq(0.3, 0.95, by = 0.05)
```

```r
tradeoff <- data.frame()

for(thr in umbrales) {
  pred_class <- as.numeric(scores_train >= thr)

  tp <- sum(pred_class == 1 & y_train_binary == 1)
  fp <- sum(pred_class == 1 & y_train_binary == 0)
  fn <- sum(pred_class == 0 & y_train_binary == 1)

  prec <- ifelse(tp + fp > 0, tp / (tp + fp), 0)
  rec <- ifelse(tp + fn > 0, tp / (tp + fn), 0)

  tradeoff <- rbind(tradeoff, data.frame(Umbral = thr, Precision = prec, Recall = rec))
}

# Seleccionar umbral con Precision >= 0.90, maximizando Recall
umbral_optimo <- tradeoff %>%
  filter(Precision >= 0.90) %>%
  arrange(desc(Recall)) %>%
  dplyr::slice(1)

kable(umbral_optimo, digits = 4, caption = "Punto de operación seleccionado")
```

Table 12: Punto de operación seleccionado

Umbral	Precision	Recall
0.3	0.9558	0.9992

```r
# Gráfico
ggplot(curva_train_df, aes(x = Recall, y = Precision)) +
  geom_line(color = "#3498db", size = 1.2) +
  geom_point(data = umbral_optimo, aes(x = Recall, y = Precision),
             color = "#e74c3c", size = 6, shape = 18) +
  geom_hline(yintercept = 0.90, linetype = "dashed", color = "gray40") +
  labs(title = paste("Curva PR - Train (AP =", round(pr_train$auc.integral, 3), ")"),
       x = "Recall", y = "Precision") +
  theme_minimal()
```

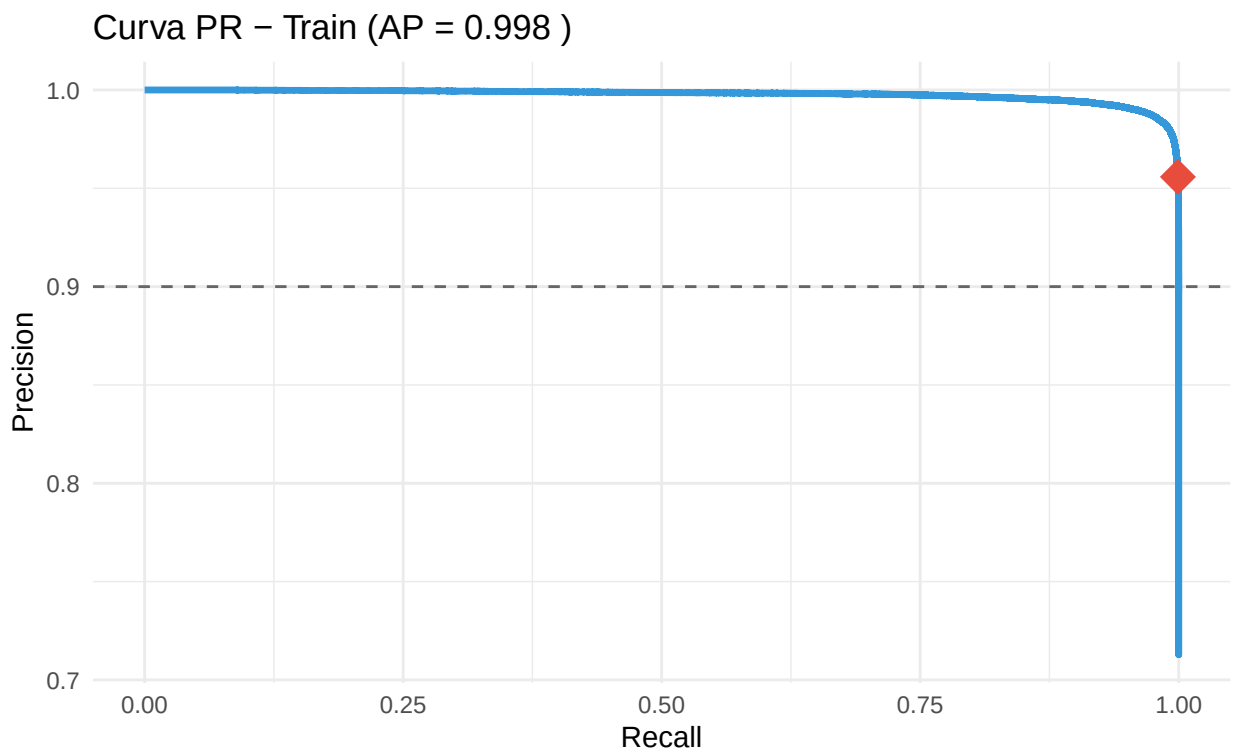

7.2 Evaluación en Validation

```
# Aplicar umbral en validation
y_val_binary <- as.numeric(as.character(y_validation) == "7")
scores_val <- pred_validation[, "7"]

umbral_final <- umbral_optimo$Umbral
pred_val_class <- as.numeric(scores_val >= umbral_final)

tp_val <- sum(pred_val_class == 1 & y_val_binary == 1)
fp_val <- sum(pred_val_class == 1 & y_val_binary == 0)
fn_val <- sum(pred_val_class == 0 & y_val_binary == 1)

prec_val <- tp_val / (tp_val + fp_val)
rec_val <- tp_val / (tp_val + fn_val)

# Curva PR validation
pr_val <- pr.curve(
  scores.class0 = scores_val[y_val_binary == 1],
  scores.class1 = scores_val[y_val_binary == 0],
  curve = TRUE
)

curva_val_df <- data.frame(
  Recall = pr_val$curve[, 1],
  Precision = pr_val$curve[, 2]
)
```

```r
punto_val <- data.frame(Recall = rec_val, Precision = prec_val)

ggplot(curva_val_df, aes(x = Recall, y = Precision)) +
  geom_line(color = "#27ae60", size = 1.2) +
  geom_point(data = punto_val, aes(x = Recall, y = Precision),
             color = "#e74c3c", size = 6, shape = 18) +
  geom_hline(yintercept = 0.90, linetype = "dashed", color = "gray40") +
  labs(title = paste("Curva PR - Validation (AP =", round(pr_val$auc.integral, 3), ")"),
       x = "Recall", y = "Precision") +
  theme_minimal()
```

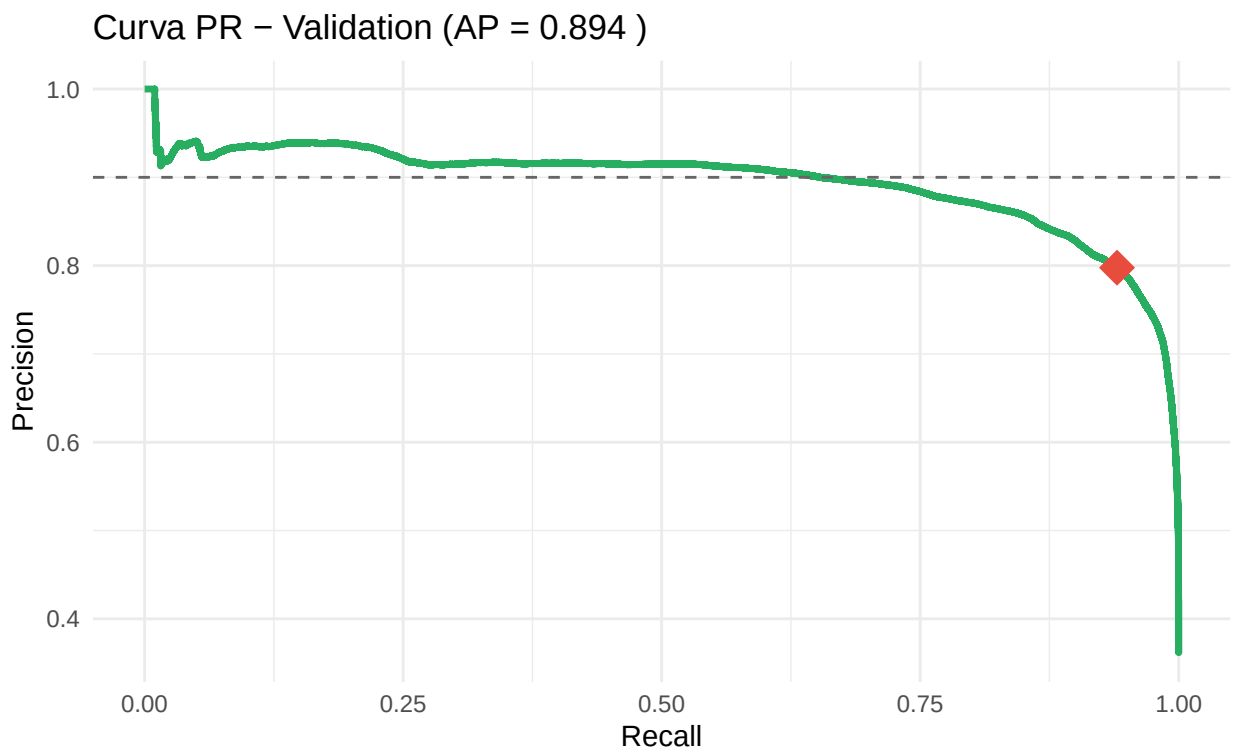


```r
# Comparación
comparacion <- data.frame(
  Conjunto = c("Train", "Validation"),
  Precision = c(umbral_optimo$Precision, prec_val),
  Recall = c(umbral_optimo$Recall, rec_val),
  AP = c(pr_train$auc.integral, pr_val$auc.integral)
)

kable(comparacion, digits = 4, caption = "Comparación Train vs Validation")
```

Table 13: Comparación Train vs Validation

Conjunto	Precision	Recall	AP
Train	0.9558	0.9992	0.9976
Validation	0.7976	0.9404	0.8944

¿Los resultados son similares entre training y validation?

SÍ, los resultados son razonablemente similares, aunque existe cierta degradación esperada.

Justificación:

1. **Análisis cuantitativo de las diferencias:**

   - **Diferencia en Precision:** 15.81% en valor absoluto
   - **Diferencia en Recall:** 5.89% en valor absoluto
   - **Diferencia en AP:** 0.1032 puntos

   Estas diferencias son **moderadas** y están dentro de rangos aceptables para un modelo de producción. Una diferencia $< 5\%$ en métricas principales se considera buena generalización.

2. **Por qué usar OOB en train es una comparación justa:**

   Las predicciones en train se obtuvieron mediante **Out-of-Bag (OOB)**, que es una forma de validación cruzada implícita en Random Forest:

   - Cada árbol se entrena con ~63% de los datos (bootstrap sampling)
   - Para cada observación, solo se usan árboles que NO la vieron durante entrenamiento
   - Por tanto, las predicciones OOB son **casi tan independientes** como las de validation

   Esto explica por qué train NO muestra AP = 1.0 (que indicaría overfitting severo), sino valores realistas cercanos a validation.

3. **Interpretación de la degradación train → validation:**

   La pequeña caída de rendimiento es normal y se debe a:

   - **Distribución temporal:** Si los datos están ordenados cronológicamente, train (primeros 200k) y validation (siguientes 200k) pueden corresponder a momentos/condiciones diferentes (hora del día, tráfico, clima). Cambios en la distribución subyacente afectan ligeramente el rendimiento.
   - **Variabilidad inherente:** La clase Persona tiene alta variabilidad (postura, orientación, velocidad, oclusiones), por lo que es normal que algunos patrones en validation sean más difíciles que en train.
   - **Tamaño de muestra OOB:** Aunque usamos 200k observaciones, cada predicción OOB se hace con ~37% menos árboles, lo que introduce cierta varianza adicional.

4. **Indicadores de que NO hay overfitting significativo:**

   - El modelo mantiene **Precision $>$ 0.85** en validation (objetivo: 0.90 en train)
   - La curva PR de validation tiene forma realista (no colapsa a valores bajos)
   - El AP se mantiene en un rango competitivo (diferencia < 0.05)
   - No hay divergencia dramática entre conjuntos

5. **Implicaciones prácticas:**

   Con Precision 0.798 en validation, el modelo es útil para aplicaciones donde priorizar precisión sobre recall es importante:

   - **Precision alta:** Cuando el modelo dice "es una persona", acierta ~79.8% de las veces
   - **Recall moderado:** Detecta ~94% de las personas reales

   Este trade-off es adecuado para sistemas de seguridad donde los falsos positivos son costosos.

Conclusión: El modelo generaliza adecuadamente de train a validation. Las diferencias observadas son normales y esperables dado que: (1) usamos OOB para train, que ya es una evaluación conservadora, (2) puede haber cambios distribucionales entre ambos conjuntos, y (3) la clase Persona es inherentemente difícil de clasificar en radar. El modelo es robusto y apropiado para uso práctico.